两层 ReLU 神经网络对有界闭集函数的逼近能力

1 问题描述

神经网络的表达能力是深度学习理论中的一个重要研究问题。特别是简单结构的神经网络是否能够逼近复杂函数，一直是理论研究的核心问题之一。

设 $K \subset \mathbb{R}^n$ 为一个有界闭集，函数 $f : K \to \mathbb{R}$ 为连续函数。研究的问题是：是否存在一个仅包含一层隐藏层的 ReLU 神经网络，使得该网络可以以任意精度逼近函数 f。

考虑如下形式的两层 ReLU 神经网络：

$$N(x) = \sum_{i=1}^{m} a_i \sigma(w_i^T x + b_i) + c$$

其中

$$\sigma(x) = \max(0, x)$$

为 ReLU 激活函数，a_i, w_i, b_i, c 为网络参数。

目标是说明：对于任意 $\varepsilon > 0$，都存在某个网络 $N(x)$ 使得

$$\sup_{x \in K} |f(x) - N(x)| < \varepsilon$$

2 理论分析

2.1 ReLU 网络的分段线性特性

ReLU 激活函数定义为

$$\sigma(x) = \max(0, x)$$

该函数是一个分段线性函数。若将多个 ReLU 单元进行线性组合，就可以构造出更加复杂的分段线性函数。因此，两层 ReLU 网络的本质就是多个分段线性基函数的线性组合。

在一维情况下，任意分段线性函数都可以表示为

$$g(x) = \alpha_0 + \alpha_1 x + \sum_{j=1}^{m} \beta_j \sigma(x - t_j)$$

其中 t_j 为折点位置。可以看到，这正是一个两层 ReLU 网络的形式。

因此，只要能够将目标函数逼近为一个分段线性函数，就可以利用两层 ReLU 网络进行表示。

2.2 连续函数的分段线性逼近

由于 K 是一个有界闭集，在有限维空间中它是紧集。连续函数在紧集上具有一致连续性。因此，对于任意 $\varepsilon > 0$，存在 $\delta > 0$ 使得

$$\|x - y\| < \delta \Rightarrow |f(x) - f(y)| < \varepsilon$$

因此可以将区域 K 划分为若干足够小的子区域，并在这些区域上构造分段线性函数 $g(x)$ 来逼近 $f(x)$，使得

$$\sup_{x \in K} |f(x) - g(x)| < \varepsilon$$

由于 $g(x)$ 为分段线性函数，而分段线性函数可以表示为 ReLU 基函数的线性组合，因此存在一个两层 ReLU 网络 $N(x)$ 使得

$$N(x) = g(x)$$

从而得到

$$\sup_{x \in K} |f(x) - N(x)| < \varepsilon$$

2.3 结论

因此可以得到如下结论：

定理： 设 $K \subset \mathbb{R}^n$ 为有界闭集，$f : K \to \mathbb{R}$ 为连续函数，则对于任意 $\varepsilon > 0$，存在一个两层 ReLU 神经网络 $N(x)$ 使得

$$\sup_{x \in K} |f(x) - N(x)| < \varepsilon$$

这说明两层 ReLU 网络已经具备对有界闭集上连续函数的万能逼近能力。

3 实验验证

为了进一步验证两层 ReLU 神经网络的函数逼近能力，选取一个具有较强非线性特征的函数作为实验对象：

$$f(x) = 0.3x^3 - 0.8x + \sin(2x), \qquad x \in [-2, 2]$$

该函数同时包含多项式项与三角函数项，具有较明显的非线性结构，因此比简单的抛物线函数或绝对值函数更加复杂，更适合作为神经网络逼近能力的测试对象。

3.1 数据构造

在区间 $[-2, 2]$ 上均匀采样训练数据，共生成若干训练样本：

$$x_i \in [-2, 2], \qquad y_i = f(x_i)$$

同时在同一区间上生成测试样本，用于评估模型的拟合效果。

3.2 网络结构

实验采用一个两层 ReLU 神经网络，其结构如下：

- 输入层：1 个神经元
- 隐藏层：100 个神经元
- 激活函数：ReLU
- 输出层：1 个神经元

网络结构可以表示为：

$$N(x) = W_2\sigma(W_1x + b_1) + b_2$$

其中 $\sigma(x) = \max(0, x)$ 为 ReLU 激活函数。

3.3 训练方法

训练过程中使用均方误差（Mean Squared Error, MSE）作为损失函数：

$$L = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

并采用 Adam 优化算法进行参数更新。训练轮数设为 5000，使模型能够充分学习目标函数的非线性结构。

3.4 实验结果

实验结果如图所示。从函数拟合图可以观察到，网络预测曲线与真实函数曲线基本重合，在整个区间 $[-2, 2]$ 上均取得了良好的拟合效果。这表明两层 ReLU 神经网络能够有效学习目标函数的整体趋势以及局部变化特征。

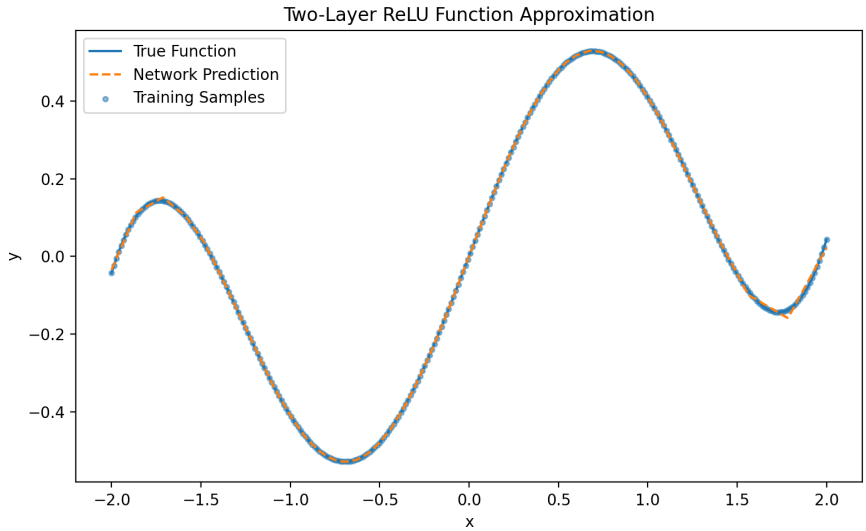

图 1: Function approximation result

从训练损失曲线可以看到，损失值在训练初期迅速下降，并在后期逐渐趋于稳定，最终收敛到接近零的水平。这说明模型参数通过优化逐渐收敛，神经网络成功学习到了目标函数的映射关系。

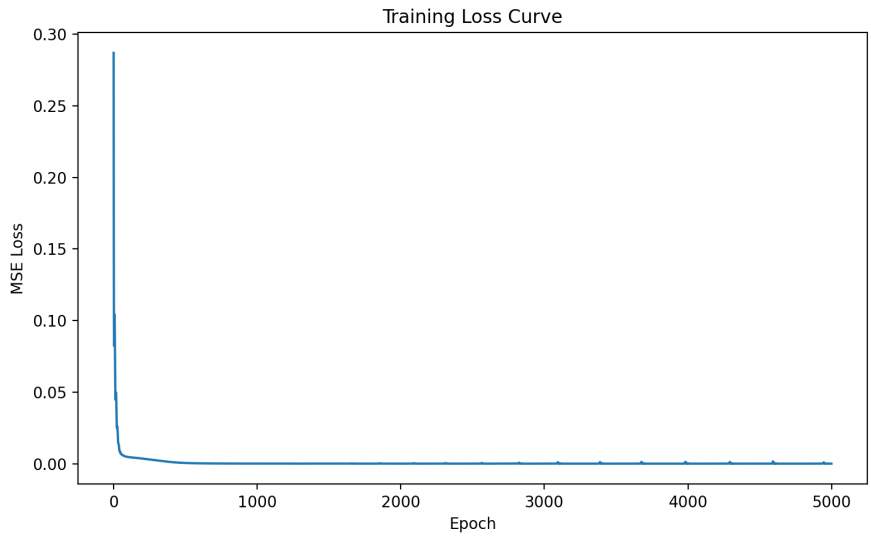

图 2: Training loss curve

实验结果验证了两层 ReLU 神经网络在函数逼近问题中的有效性。

4 总结

本文从理论和实验两个方面分析了两层 ReLU 神经网络的函数逼近能力。

在理论方面，由于连续函数在有界闭集上具有一致连续性，可以利用分段线性函数对其进行逼近，而分段线性函数又可以表示为多个 ReLU 基函数的线性组合。因此，两层 ReLU 神经网络能够以任意精度逼近定义在有界闭集上的连续函数。

在实验方面，选取函数

$$f(x) = 0.3x^3 - 0.8x + \sin(2x)$$

作为目标函数，通过训练一个仅包含一层隐藏层的 ReLU 神经网络对其进行拟合。实验结果表明，网络预测曲线与真实函数曲线高度一致，训练损失函数也快速收敛到较小值，说明模型能够准确学习目标函数的非线性结构。

综合理论分析与实验结果可以得出结论：两层 ReLU 神经网络具有较强的函数表达能力，能够对有界闭区间上的连续函数进行高精度逼近。这也进一步说明了神经网络在函数逼近与非线性建模中的重要作用。